最优化方法数学知识回顾

学习最优化方法之前，系统梳理所需的数学基础——

向量、范数、内积、矩阵、导数、凸分析与泛函

内容目录

01 空间与集合

$\mathbb{R}^n$ / E^n / 凸集 / 紧集 / 可行域

02 向量与内积

向量运算 / 内积 / 正交性 / Cauchy-Schwarz

03 范数（Norm）

L_1 / L_2 / $L\infty$ / 加权范数 / 等价性

04 矩阵与特征值 ★

正定矩阵 / 特征值计算 / 物理意义 / 条件数

05 导数与展开

梯度 / Hessian / Jacobian / Taylor 展开

06 凸分析

凸函数判定 / 凸优化性质 / Jensen 不等式

07 泛函初步

泛函概念 / 欧拉-拉格朗日方程

08 概念关系总图

从 $\mathbb{R}^n$ 到凸分析的完整知识脉络

空间与集合

最优化问题的"工作空间"——问题定义在哪里?

基本空间

- $\mathbb{R}^n$ ：n 维实数空间，仅代数结构
- $\mathbf{E}^n$ ：$\mathbb{R}^n$ + 标准内积 → 欧几里得空间
- $\mathbb{Z}^n$ ：整数格点空间（整数规划）

重要集合类型

- **凸集** ：$\forall x,y \in C, \lambda x+(1-\lambda)y \in C$（线段在集合内）
- **紧集** ：有界闭集，连续函数可取最值
- **仿射集** ：凸集 + 可延拓至整个直线

无约束优化标准形式

$$min\ f(x)，\ x \in E^n$$

在整个 n 维欧几里得空间中寻找最优解

约束优化标准形式

$$min\ f(x)\ s.t.\ g_i(x) \le 0,\ h_j(x)=0$$

可行域 $\Omega = \{x \mid g_i(x) \le 0,\ h_j(x)=0\}$

向量与内积

向量的"长度"和"夹角"如何定义?

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \cdots \\ x_n \end{bmatrix}$$

向量的基本运算

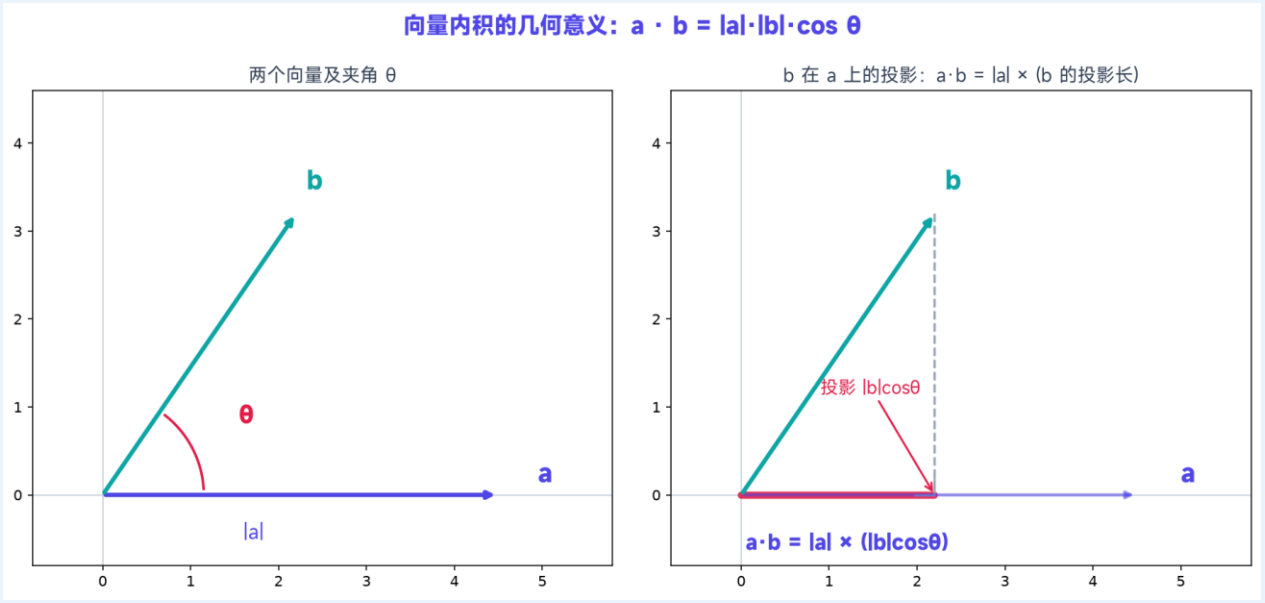
- **加法** ： $x+y = (x_1+y_1, \ldots, x_n+y_n)$
- **数乘** ： $\alpha x = (\alpha x_1, \ldots, \alpha x_n)$
- **内积** ： $\langle x,y \rangle = \Sigma x_i y_i = x^T y$

欧几里得内积

$$\langle x,y \rangle = x^T y = \Sigma x_i y_i$$

内积的几何意义：

- $\langle x,y \rangle = \|x\| \|y\| \cos\theta$（θ 为夹角）
- $\langle x,y \rangle = 0 \Leftrightarrow x \perp y$（正交）

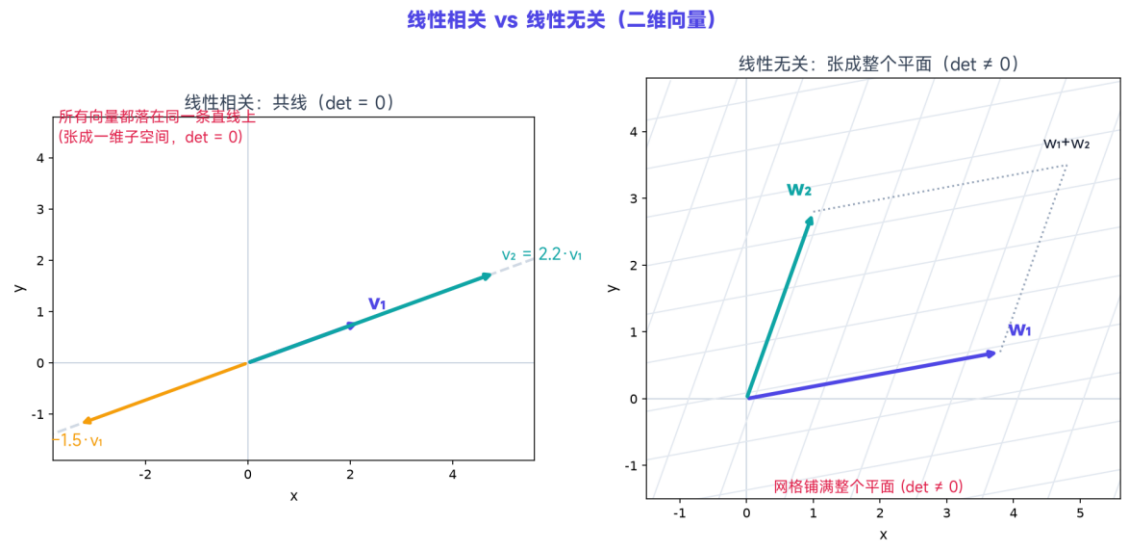


向量与内积

向量的"长度"和"夹角"如何定义?

线性相关与基

- **线性无关** ：$\Sigma\alpha_i v_i=0 \Rightarrow$ 所有 $\alpha_i=0$
- **基** ：一组线性无关向量，张成整个空间
- **维数** ：基中向量的个数 dim(V)

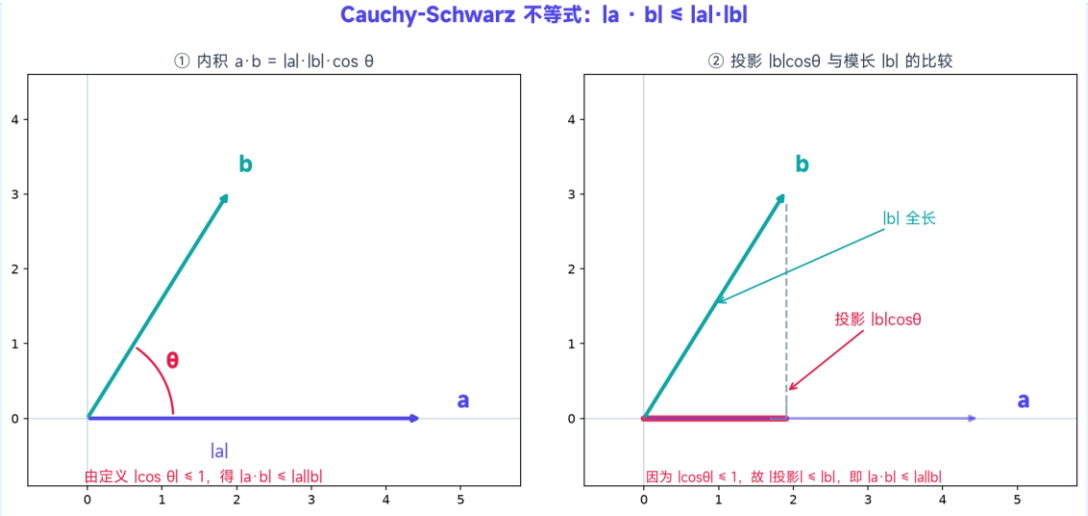


Cauchy-Schwarz 柯西-施沃茨不等式

$$|\langle x,y\rangle| \le \|x\|\cdot\|y\|$$

等号成立 ⇔ x 与 y 共线（线性相关）

→ 梯度方向是函数值上升最快的方向



优化中的角色：方向导数 $D_d f(x)=\langle \nabla f(x),d\rangle$，梯度下降法利用这个内积关系

范数（Norm）——向量的"长度"度量

不同的范数定义不同的距离概念，适用于不同的问题场景

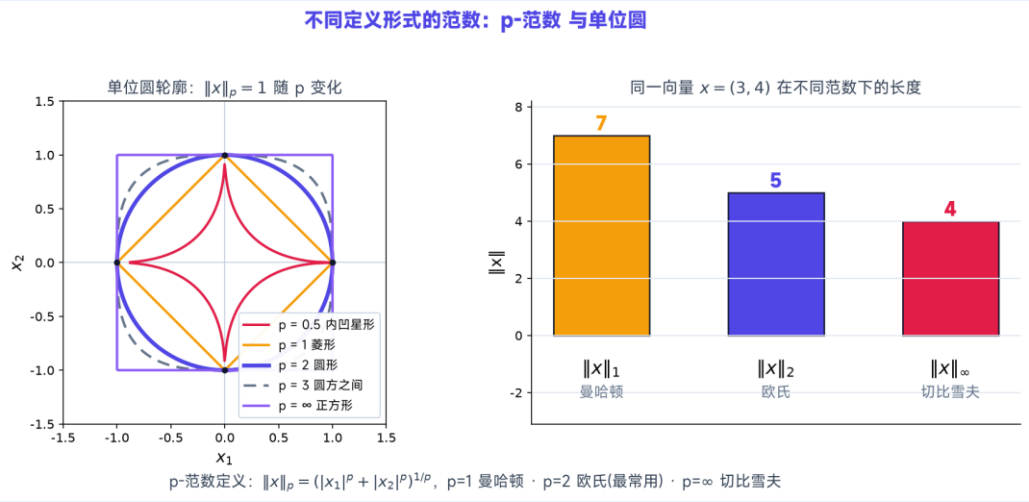
范数	定义式	几何意义	典型应用
L_1 范数	$\|x\|_1 = \Sigma\|x_i\|$	曼哈顿距离	稀疏优化、Lasso回归
L_2 范数	$\|\|x\|\|_2=\sqrt{\sum x_i^2}$	欧几里得距离	最小二乘、梯度法
L_∞ 范数	$\|x\|_\infty = \max\|x_i\|$	切比雪夫距离	鲁棒优化、逼近论
p-范数	$\|x\|_p = (\Sigma x_i^p)^{(1/p)}$	p=1,2,∞ 的推广	一般理论分析
加权 L_2 范数	$\|x\|_W=\sqrt{(x^TWx)}$	椭球范数	信赖域、牛顿法
Frobenius 范数	$\|A\|_F=\sqrt{(\Sigma a_{ij}^2)}$	矩阵的 L_2 范数	矩阵逼近、PCA
谱范数	$\|A\|_2=\sigma_{max}(A)$	最大奇异值	条件数、数值稳定性

举例： $x = (3, 4)$

$||x||_2 = \sqrt{(3^2 + 4^2)} = 5$（直线距离）

$||x||_1 = |3| + |4| = 7$（曼哈顿距离）

$||x||_\infty = \max(3, 4) = 4$（最大偏差）



注意： ||x|| 与 // x // 表示相同意义，只是写法的差异

范数的等价性

在有限维空间 $\mathbb{R}^n$ 中，所有范数都是等价的

范数等价定义

存在常数 $c_1, c_2 > 0$，使得：

$$c_1\|x\| \le \|x\|_b \le c_2\|x\|_a$$

→ 在 $\mathbb{R}^n$ 中，收敛性不依赖于范数选择—只要在某范数下收敛，在所有范数下都收敛

常用等价关系

$\|x\|_2 \le \|x\|_1 \le \sqrt{n}\|x\|_2$

$\|x\|_\infty \le \|x\|_2 \le \sqrt{n}\|x\|_\infty$

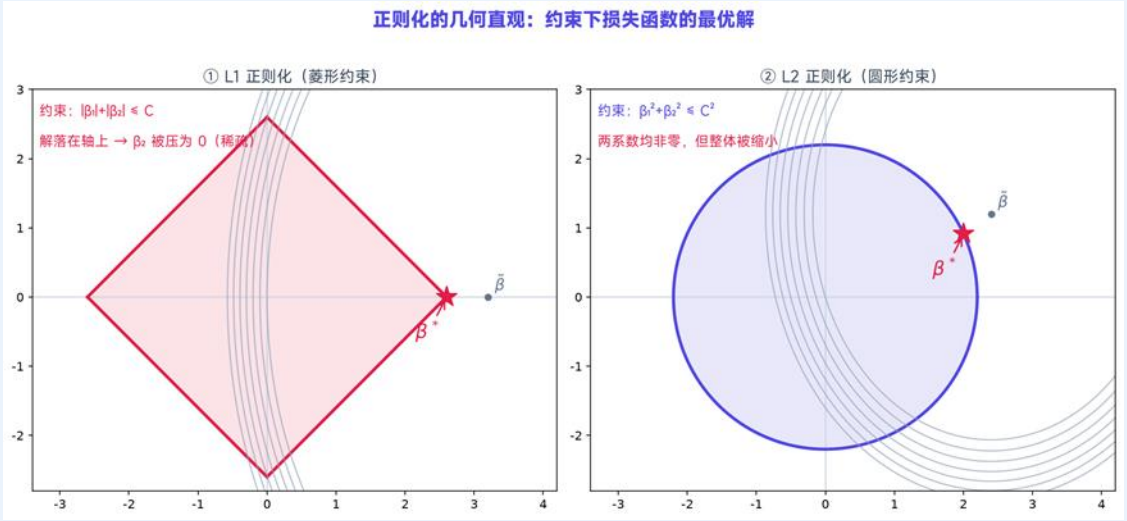
$\|x\|_\infty \le \|x\|_1 \le n\|x\|_\infty$

范数在优化中的角色

- **梯度法**：$\|\nabla f\|_2 < \varepsilon$ 判断收敛
- **正则化**：L_1 产生稀疏解，L_2 防止过拟合
- **信赖域**：加权 $\|d\|_W \le \Delta$ 定义信任区域

正则化：给优化问题"加点约束"，防止模型/解被数据牵着走得太离谱

$$min_\theta\ L(\theta) \Rightarrow min_\theta\ L(\theta) + \lambda\|\theta\|$$



矩阵与特征值（基础）

矩阵是线性变换的表示，特征值揭示变换的"缩放"本质

矩阵基本概念

对称矩阵 ： $A=A^T$，特征值全为实数

对角矩阵 ： $diag(d_1,...,d_n)$，非对角元为零

迹 ： $tr(A)=\Sigma a_{ii}=\Sigma\lambda_i$　　**行列式** ： $det(A)=\Pi\lambda_i$

det(A) 是矩阵的行列式(determinant)。
几何意义：矩阵线性变换时的体积缩放因子，det(A)>0，体积放大|det(A)|倍；det(A)=0，矩阵奇异，不可逆，变换将空间压缩到更低维度（体积坍缩为0）

$$A=\begin{bmatrix} a & b \\ c & d \end{bmatrix}$$ det(A)=ad-bc

$$A=\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

$$det(A) = a_{11}\cdot a_{22}\cdot a_{33} + a_{12}\cdot a_{23}\cdot a_{31} + a_{13}\cdot a_{21}\cdot a_{32} - a_{13}\cdot a_{22}\cdot a_{31} - a_{11}\cdot a_{23}\cdot a_{32} - a_{12}\cdot a_{21}\cdot a_{33}$$

$$A=\begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 3 \end{bmatrix}$$ det(A)=20

$\lambda_1=5, \lambda_2=2, \lambda_3=2, \Pi\lambda_i=20$

阶数	项数	可用方法
2×2	2! = 2	直接公式 ad - bc
3×3	3! = 6	**Sarrus 法则**（对角线法）
4×4	4! = 24	Laplace 展开、行变换
n×n	n!	行变换（最常用）、Laplace 展开

矩阵与特征值（基础）

矩阵是线性变换的表示，特征值揭示变换的"缩放"本质

特征值：直观理解

特征值 λ 和特征向量 v 满足：

$$Av = \lambda v$$

几何意义：矩阵 A 作用在特征向量 v 上，只改变长度（缩放 λ 倍），不改变方向

如何计算特征值?

Step 1：写出特征方程

$$\det(A - \lambda I) = 0$$

Step 2：展开行列式，得到 λ 的 n 次多项式

Step 3：解多项式求 $\lambda_1, \lambda_2, \ldots, \lambda_n$

Step 4：对每个 λ_i，解 $(A-\lambda_i I)v=0$ 得特征向量

实例：2×2 矩阵

A = [[3, 1], [1, 3]]

$$A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

$$\det(A-\lambda I) = (3-\lambda)^2 - 1 = 0$$

$$\rightarrow \lambda^2 - 6\lambda + 8 = 0$$

$\rightarrow \lambda_1=4$（对应 $v_1 = [1,1]^T$），$\lambda_2=2$（对应 $v_2 = [1,-1]^T$）

验证：$A \cdot v_1 = [4,4]^T = 4 \cdot v_1$ ✓

$Av = \lambda v \quad \rightarrow \quad (A - \lambda I)v = 0$

v 是非零向量，所以 (A - λI) 必须是奇异矩阵

v 特征向量是矩阵 A 作用后方向不变（仅被拉伸/压缩）的特殊向量，λ 就是拉伸倍数。

直观理解： 把矩阵 A 看作一个"变换器"，输入一个向量 v，输出 Av。对大多数向量，输出方向会改变；但对特征向量，输出方向不变，只是长度乘以 λ 倍。

矩阵与特征值（基础）

矩阵是线性变换的表示，特征值揭示变换的"缩放"本质

物理意义：拉伸与方向

- **|λ| > 1**：沿该特征向量方向 **拉伸**
- **|λ| < 1**：沿该特征向量方向 **压缩**
- **λ < 0**：沿该特征向量方向 **反向**
- **λ = 0**：该方向被 **压缩到零** （矩阵奇异）

特征值在优化中的角色

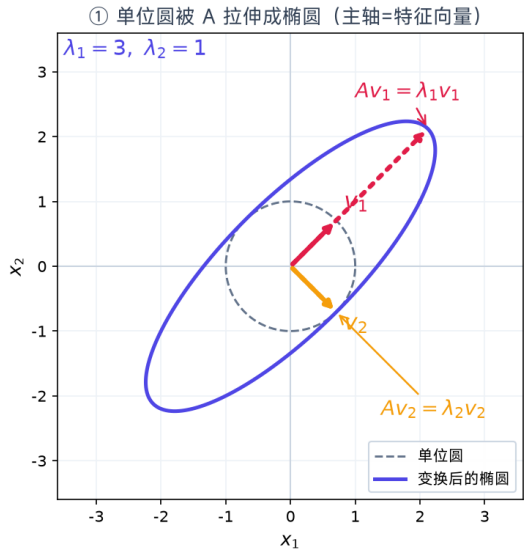
概念	与特征值的关系
Hessian 正定	所有 $\lambda_i > 0$ → 局部极小
条件数 κ	$\lambda_{max}/\lambda_{min}$ → 收敛速度
牛顿法	用 Hessian^{-1} 缩放梯度，消除特征值差异
PCA	协方差矩阵的特征向量 = 主成分方向
瑞利商	$R(x)=(x^TAx)/(x^Tx)$，极值=$\lambda_{max/min}$

一句话总结：特征值 λ 回答"矩阵沿某个方向拉伸了多少倍"，特征向量 v 回答"哪个方向"。Hessian 的特征值分布决定了最优化问题的求解难度。

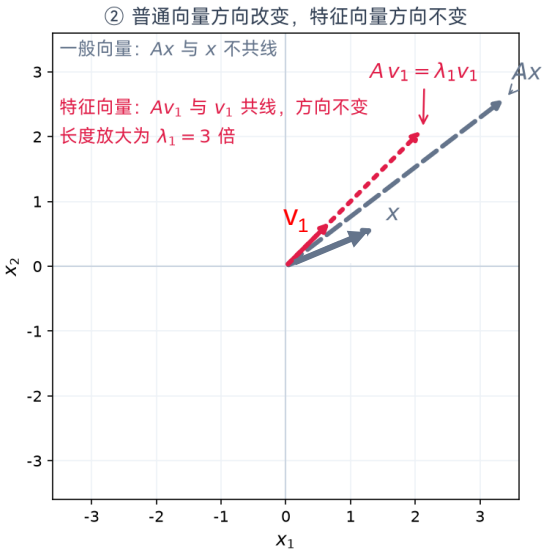
$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

$$v1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix} \approx \begin{bmatrix} 0.707 \\ 0.707 \end{bmatrix} \qquad v2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix} \approx \begin{bmatrix} 0.707 \\ -0.707 \end{bmatrix}$$

矩阵特征值 λ 与特征向量：$Ax = \lambda x$ 的几何意义



特征值决定拉伸倍数、
特征向量决定拉伸方向



Ax = λx 的本质是
矩阵在该方向退化为数乘 λ

矩阵与特征值（基础）

矩阵是线性变换的表示，特征值揭示变换的"缩放"本质

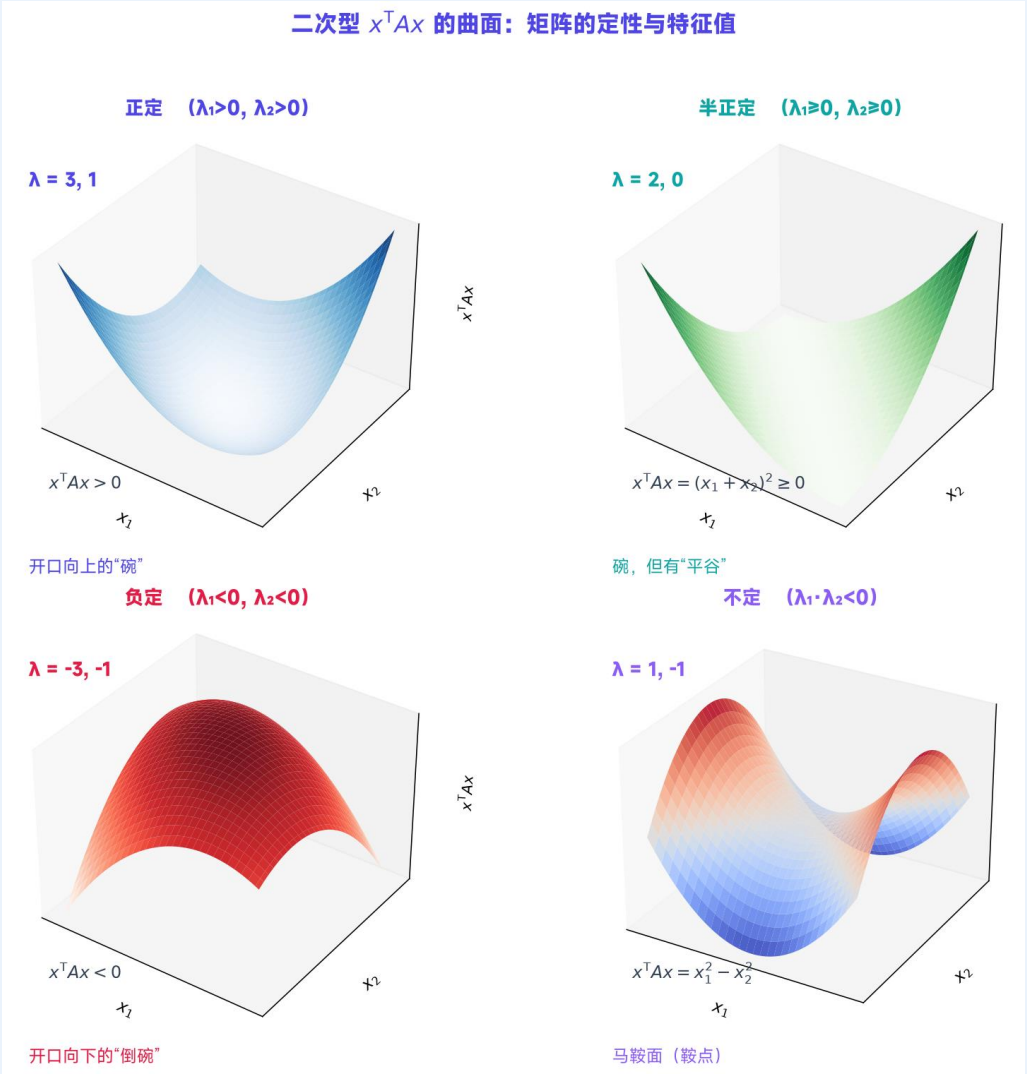
条件数

$$\kappa(A) = \|A\|.\|A^{-1}\| = \lambda_{max} / \lambda_{min}$$

衡量矩阵的“病态程度”：κ 越大 → 矩阵越"病态" → 梯度法 zigzag 越严重

正定矩阵判定（最优化核心）

类型	定义	特征值	Hessian含义
正定	$x^TAx>0$	$\lambda_i>0$	局部极小
半正定	$x^TAx\geq0$	$\lambda_i\geq0$	凸函数
负定	$x^TAx<0$	$\lambda_i<0$	局部极大
不定	可正可负	有正有负	鞍点



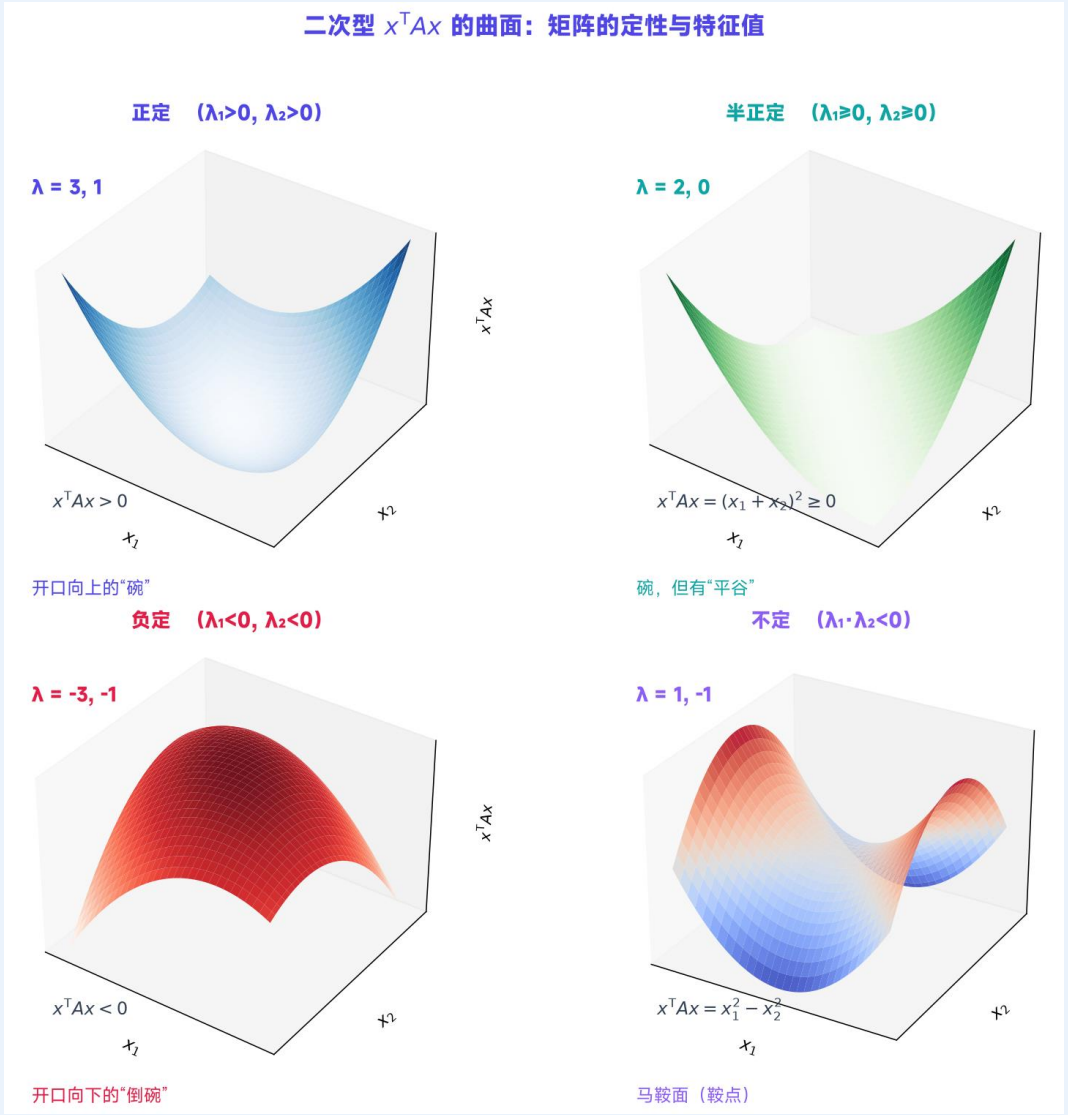
矩阵与特征值（基础）

矩阵是线性变换的表示，特征值揭示变换的"缩放"本质

正定矩阵判定（最优化核心）

类型	定义	特征值	Hessian含义
正定	$x^TAx>0$	$\lambda_i>0$	局部极小
半正定	$x^TAx\geq0$	$\lambda_i\geq0$	凸函数
负定	$x^TAx<0$	$\lambda_i<0$	局部极大
不定	可正可负	有正有负	鞍点

定性	矩阵 A	特征值 λ	二次型 x^TAx
正定	$\begin{bmatrix}2 & 1\\1 & 2\end{bmatrix}$	3, 1	$2x_1^2+2x_1x_2+2x_2^2$
半正定	$\begin{bmatrix}1 & 1\\1 & 1\end{bmatrix}$	2, 0	$(x_1+x_2)^2$
负定	$\begin{bmatrix}-2 & -1\\-1 & -2\end{bmatrix}$	−3, −1	$-(2x_1^2+2x_1x_2+2x_2^2)$
不定	$\begin{bmatrix}1 & 0\\0 & -1\end{bmatrix}$	1, −1	$x_1^2-x_2^2$



梯度（Gradient）

多元函数的一阶导数——最优化方法中最核心的概念

定义

对 f(x):$\mathbb{R}^n \to \mathbb{R}$，梯度是偏导数组成的向量：

$$\nabla f(x) = (\partial f/\partial x_1, \partial f/\partial x_2, \ldots, \partial f/\partial x_n)^T \qquad \nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \cdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix}$$

方向导数

沿方向 u 的瞬时变化率：

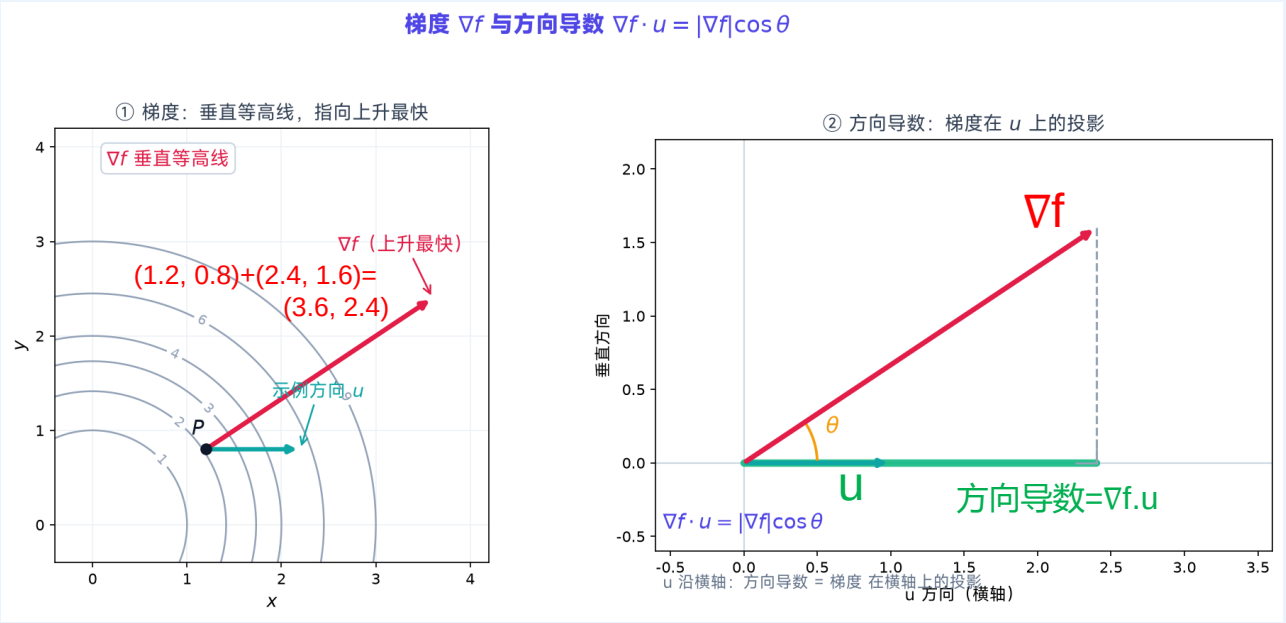
$$D_d f(x) = \langle \nabla f(x), u \rangle = \nabla f(x)^T u$$

几何意义（极其重要！）

- ↑ **梯度方向** = 函数值 **上升最快** 的方向
- ↓ **负梯度方向** = 函数值 **下降最快** 的方向
- 梯度 **垂直于** 函数的等值面（水平集）

梯度下降法：$x_{k+1} = x_k - \eta \nabla f(x_k)$

沿负梯度方向前进，每次迭代使函数值下降。—— 这是最优化方法的第一原理！



$f(x,y)=x^2+y^2$

$\nabla f \cdot u = |\nabla f| \cos\theta$

$$\nabla f(x,y) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 2x \\ 2y \end{bmatrix} \qquad \nabla f(1.2,0.8) = \begin{bmatrix} 2.4 \\ 1.6 \end{bmatrix}$$

P=(1.2,0.8) $|\nabla f| = \sqrt{2.4^2 + 1.6^2} = 2\sqrt{x^2+y^2} = 2.884$

梯度的模/长度/范数

Hessian 矩阵

多元函数的曲率信息——二阶导数，判断极值类型的依据

定义

Hessian 是二阶偏导组成的 n×n 对称矩阵：

$$\nabla^2 f(x) = [\partial^2 f/(\partial x_i \partial x_j)]$$

$$H(X)=\begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}, \frac{\partial^2 f}{\partial x_1 \partial x_2} \cdots\cdots, \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \cdots\cdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}, \frac{\partial^2 f}{\partial x_n \partial x_2} \cdots\cdots, \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

几何意义

- Hessian 描述函数在一点处的 **局部曲率**
- 正定 → 局部向上弯曲 → 极小值
- 负定 → 局部向下弯曲 → 极大值
- 不定 → 鞍点（一个方向向上，一个方向向下）

梯度、Hessian、Jacobian 对比

对象	类型	维度	优化中的角色
梯度 ∇f	向量	n×1	确定搜索方向
Hessian ∇²f	矩阵	n×n	曲率信息、判断极值
Jacobian JF	矩阵	m×n	向量值函数导数

$$J(X)=\begin{bmatrix} \frac{\partial f_1}{\partial x_1}, \frac{\partial f_1}{\partial x_2} \cdots\cdots, \frac{\partial f_1}{\partial x_n} \\ \cdots\cdots \\ \frac{\partial f_n}{\partial x_1}, \frac{\partial f_n}{\partial x_2} \cdots\cdots, \frac{\partial f_n}{\partial x_n} \end{bmatrix}$$

一阶 vs 二阶方法

1 **一阶方法** （梯度法）：仅用梯度，每步 O(n)

2 **二阶方法** （牛顿法）：用梯度+Hessian，每步 $O(n^3)$

Taylor 展开——最优化方法的理论基础

用多项式近似复杂函数，一阶→梯度法，二阶→牛顿法

一维 Taylor 展开

$$f(x+h)=f(x)+f'(x)h+\frac{1}{2}f''(x)h^2+O(h^3)$$

一阶近似：线性，二阶近似：抛物线

多维 Taylor 展开

一阶（线性近似）：

$$f(x+d)=f(x)+\nabla f(x)^T d+o(\|d\|)$$

二阶（二次近似）：

$$f(x+d)=f(x)+\nabla f(x)^T d+\frac{1}{2}d^T\nabla^2 f(x)d+o(\|d\|^2)$$

Taylor 展开在优化中的角色

- **梯度法** ：使用 **一阶展开** ，取 $d=-\eta\nabla f(x)$

  $f(x-\eta\nabla f)=f(x)-\eta\|\nabla f\|^2+\ldots \rightarrow$ 函数值下降

- **牛顿法** ：使用 **二阶展开** ，令导数=0

  $d=-[\nabla^2 f(x)]^{-1}\nabla f(x) \rightarrow$ 一步到极小点（二次函数）

- **信赖域法** ：在半径 Δ 内最小化二阶模型

核心思想：梯度法用"平面"近似曲面，牛顿法用"抛物面"近似曲面。

凸集与凸函数

"凸" = 任意两点连线都在内部 → 没有"坑坑洼洼"

凸集

集合 C 是凸的，如果：

$$\forall x,y \in C,\ \lambda \in [0,1]:\ \lambda x+(1-\lambda)y \in C$$

几何：连接任意两点的线段完全在集合内

凸函数定义

函数 f 是凸的，如果：

$$f(\lambda x+(1-\lambda)y) \le \lambda f(x)+(1-\lambda)f(y)$$

几何：任意两点连线在函数图像之上

凸函数判定条件

条件	数学表述
一阶条件	$f(y) \ge f(x)+\nabla f(x)^T(y-x)$
二阶条件	$\nabla^2 f(x)$ 半正定（$\forall x$）
Jensen	$f(\Sigma\lambda_i x_i) \le \Sigma\lambda_i f(x_i)$

常见凸函数

线性函数：$f(x)=a^Tx+b$　　二次函数：$\frac{1}{2}x^TAx$（A半正定）

范数：$\|x\|$　　指数函数：e^{ax}　　负对数：$-\ln x$

凸优化为何重要？ 凸函数的任何局部极小值都是全局极小值！

凸优化核心性质

为什么凸优化问题"好解"？—— 三大核心性质

全局最优

凸函数的任何局部极小值都是全局极小值。

$$f(x^*) = \min f(x)$$

唯一解（严格凸）

若 Hessian 正定（严格凸函数），则最优解唯一。

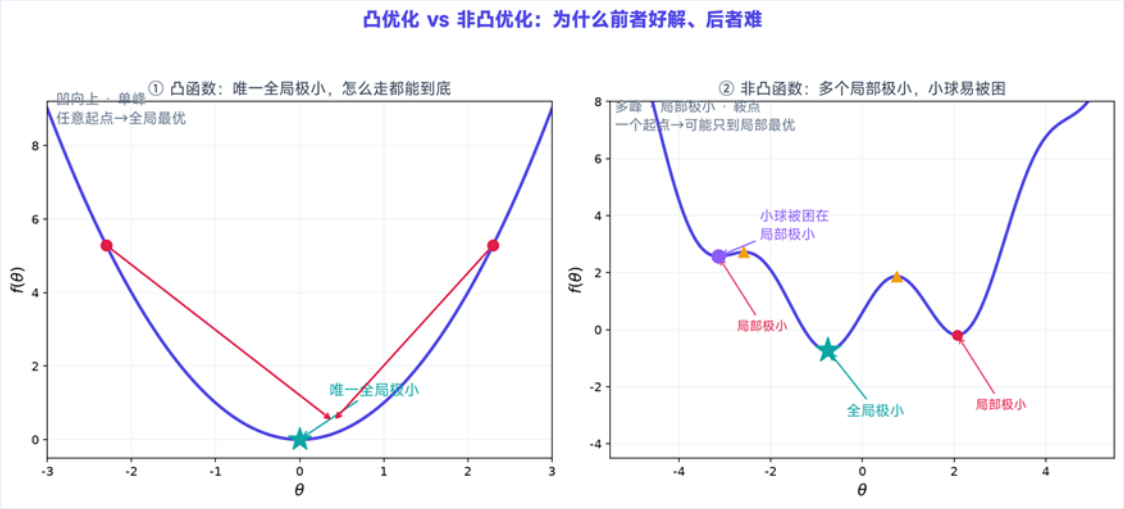
$$\nabla^2 f(x) \succ 0 \Rightarrow x^* \text{ 唯一}$$

算法可验证

梯度为零（∇f(x*)=0）是全局最优的充要条件。

$$\nabla f(x^*)=0 \Leftrightarrow x^* \text{ 全局最优}$$

对比非凸优化：神经网络训练（非凸）存在大量局部极小值和鞍点，这正是深度学习优化困难的根本原因，也是 Adam、动量法等先进优化器被提出来的动力。



泛函初步

"函数的函数"——输入是函数，输出是实数

泛函的定义

泛函是从函数空间到实数的映射：

$$J : F \to \mathbb{R}$$

F 是某个函数集合，J[f] 是实数。 “函数的函数” ：输入一个函数，输出一个实数

泛函 vs 普通函数

概念	普通函数	泛函
输入	$x \in \mathbb{R}^n$	函数 $f \in F$ （函数空间）
输出	实数 f(x)	实数 J[f]
例子	$f(x)=x^2+1$	$J[f]=\int f^2 dx$
优化目标	求 x*	求 f*使 J[f] 最小
导数	梯度∇f	变分导数 $\delta J/\delta f$

最优化中的泛函例子

- **损失函数** ： $L(f)=(1/N)\Sigma(y_i-f(x_i))^2$

  输入是预测函数 f，输出是预测误差

- **最优控制** ： 5分钟滚动的控制曲线

变分：类似微分，给整条曲线的形状一个微小扰动 δy，考察泛函的变化 δJ

泛函极值： 若泛函 J[y] 在 y*(x) 处取极值，则对任意微小扰动 δy，其一阶变分必须为零

Euler-Lagrange方程

$$\frac{\partial L}{\partial y} - \frac{d}{dx}\left(\frac{\partial L}{\partial y'}\right) = 0$$

它把一个“求整条曲线”的变分问题，转化成了一个（组）可解的微分方程。这一步是变分法能落地的关键：把“无限维的搜索”变成“有限维的微分方程”

应用例子：求连接两点的最短曲线（显然是直线）

弧长泛函：$J[y] = \int_{x_2}^{x_1} \sqrt{1+(y')^2}\,dx$

$$F = \sqrt{1+(y')^2}$$

$$\frac{\partial F}{\partial y} = 0, \qquad \frac{\partial F}{\partial y'} = \frac{y'}{\sqrt{1+(y')^2}}$$

$$0 - \frac{d}{dx}\left(\frac{y'}{\sqrt{1+(y')^2}}\right) = 0$$

Y=Cx+D 直线

数学概念关系总图

从最基础的空间出发，逐步构建最优化所需的数学体系

① 线性空间

$\mathbb{R}^n$ + 加法 + 数乘
· 线性无关 / 基 / 维数
· 子空间 / 正交补

② 内积空间 → E^n

$\mathbb{R}^n$ + 内积 $\langle \cdot, \cdot \rangle$
· 正交性 → Gram-Schmidt
· Cauchy-Schwarz 不等式

③ 赋范空间

$\mathbb{R}^n$ + 范数 $\|\cdot\|$
· L_1 → 稀疏性（Lasso）
· L_2 → 欧几里得距离
· $L\infty$ → 最大偏差
· 范数等价性

④ 凸分析

$\mathbb{R}^n$ + 凸性
· 凸集 / 凸函数 / 凸优化
· Jensen 不等式
· 全局最优解 ← 核心优势

⑤ 梯度法依赖

一阶 Taylor 展开
$\mathbb{R}^n$ → 内积 → 梯度 $\langle \nabla f, d \rangle$
→ 一阶展开 → 梯度下降

⑥ 牛顿法依赖

二阶 Taylor 展开
$\mathbb{R}^n$ → 内积 → Hessian
→ 二阶展开 → 牛顿法

从 $\mathbb{R}^n$ 出发，添加不同结构 → 不同的数学工具 → 不同的优化方法。
所有概念最终服务于**方向、步长、更新、收敛**这四个最优化核心问题。

总结

上述数学概念构成了最优化方法的完整理论基础。

从$\mathbb{R}^n$出发，经过**内积**和**范数**定义度量，

通过**梯度**和**Hessian**描述函数局部性质，

借助**Taylor 展开**构建近似模型，

利用**凸分析**保证求解的可靠性。

最优化方法四要素

方向 • 步长 • 更新 • 收敛

核心学习路径

梯度法 → 牛顿法 → 直接搜索